ТЕХНИЧЕСКОЕ ЗАДАНИЕ

LegalSearch — AI-поиск для юристов

Сервис интеллектуального правового поиска: запрос на естественном языке → релевантные нормы и практика → краткий вывод с проверяемыми ссылками.

Версия: MVP 1.0 **Команда:** Салмина А., Воробьев А. **Статус:** В разработке **Обновлено:** сентябрь 2026

1. Обзор проекта

LegalSearch решает проблему ручного поиска правовой информации: юристы тратят 17–35% рабочего времени на поиск норм и судебной практики по ключевым словам, просматривая нерелевантные документы и не доверяя AI-инструментам из-за галлюцинаций.

Продукт: B2B SaaS-сервис с семантическим поиском на основе RAG-архитектуры — ответ генерируется строго по найденным документам, каждый тезис подкреплён ссылкой на первоисточник.

УСКОРЕНИЕ ПОИСКА
2–4×
против ручного поиска

СНИЖЕНИЕ ТРУДОЗАТРАТ
40–60%
на юридический ресерч

РЫНОК SAM
10.5 млрд
рублей, РФ

ГАЛЛЮЦИНАЦИИ
0
ответ только по документам

2. Технологический стек

BACKEND

FastAPI

PostgreSQL 17

SQLAlchemy 2

HTTP API, роутинг

структурные данные

async ORM

JWT / passlib
авторизация

Docker Compose
среда разработки

AI-ПАЙПЛАЙН

Sentence-BERT
векторизация

Qdrant
векторная БД

Cross-encoder
reranking

LLaMA / Qwen
генерация (on-premise)

FRONTEND

Next.js (React)
UI

Tailwind CSS
стили

3. Архитектура системы

> MVP работает полностью on-premise: LLM и Qdrant запускаются локально. Данные клиентов не уходят во внешние API. Это принципиально важно для юридической конфиденциальности.

КОМПОНЕНТ	РОЛЬ	ПОРТ	СТАТУС
FastAPI Backend	API, бизнес-логика, сохранение в БД	`8000`	`готово`
PostgreSQL	Пользователи, история, подборки	`5432`	`готово`
Qdrant	Векторный поиск по документам	`6333`	`следующий шаг`
LLM (LLaMA/Qwen)	RAG, суммаризация, генерация ответа	—	`следующий шаг`
Next.js Frontend	UI для юристов	`3000`	`следующий шаг`

4. База данных

Все структурные данные хранятся в PostgreSQL. Векторы документов — в Qdrant (отдельный сервис).

companies

Компания-клиент

id	UUID PK	Первичный ключ
name	VARCHAR(255)	Название компании
subscription	VARCHAR(50)	trial / basic / enterprise
created_at	TIMESTAMP	Дата регистрации

users

Юрист — конечный пользователь

id	UUID PK	Первичный ключ
company_id	UUID FK	→ companies.id
email	VARCHAR UNIQUE	Логин
password_hash	VARCHAR	bcrypt
role	VARCHAR(50)	lawyer / admin
created_at	TIMESTAMP	Дата регистрации

documents

Внутренние документы компании (PDF/DOCX)

id	UUID PK	Первичный ключ
company_id	UUID FK	→ companies.id (изоляция)
uploaded_by	UUID FK	→ users.id
filename	VARCHAR(255)	Оригинальное имя файла
file_path	VARCHAR(500)	Путь на диске
indexed	BOOLEAN	Проиндексирован в Qdrant
created_at	TIMESTAMP	Дата загрузки

queries

История поисковых запросов

id	UUID PK	Первичный ключ

user_id	UUID FK	→ users.id
text	TEXT	Запрос юриста
answer	TEXT	Ответ AI
filters	JSONB	Суд, регион, период, категория
created_at	TIMESTAMP	Время запроса

query_sources

Источники, использованные AI для конкретного ответа

id	UUID PK	Первичный ключ
query_id	UUID FK	→ queries.id
document_id	VARCHAR(255)	«А40-123456/2023» или id НПА
title	VARCHAR(500)	Заголовок документа
relevance	FLOAT	Оценка релевантности 0–1
fragment	TEXT	Цитата из документа

collections

Подборки документов, созданные юристом

id	UUID PK	Первичный ключ
user_id	UUID FK	→ users.id
name	VARCHAR(255)	Название подборки
created_at	TIMESTAMP	Дата создания

collection_items

Документы внутри подборки

id	UUID PK	Первичный ключ
collection_id	UUID FK	→ collections.id
document_id	VARCHAR(255)	ID документа в Qdrant / НПА
title	VARCHAR(500)	Заголовок для отображения
added_at	TIMESTAMP	Дата добавления

5. API Эндпоинты

АВТОРИЗАЦИЯ

POST	/auth/register	Регистрация пользователя + создание компании
POST	/auth/login	Вход, возвращает JWT-токен
GET	/auth/me	Данные текущего пользователя

ПОИСК

POST	/search/	Семантический поиск + AI-ответ, сохранение в историю заглушка

ИСТОРИЯ

GET	/history/	Последние 50 запросов пользователя с источниками

ПОДБОРКИ

GET	/collections/	Список подборок пользователя
POST	/collections/	Создать подборку
POST	/collections/{id}/items	Добавить документ в подборку
DELETE	/collections/{id}	Удалить подборку

6. Ключевые схемы данных

ЗАПРОС ПОИСКА

ПОЛЕ	ТИП	ОПИСАНИЕ
query	string	Текст запроса на естественном языке

ПОЛЕ	ТИП	ОПИСАНИЕ
`filters.court`	string?	Название суда
`filters.region`	string?	Регион
`filters.date_from`	string?	Период с
`filters.date_to`	string?	Период по
`filters.category`	string?	Категория спора

ОТВЕТ ПОИСКА

ПОЛЕ	ТИП	ОПИСАНИЕ
`query_id`	UUID	ID сохранённого запроса
`answer`	string	Краткий вывод AI
`sources[].document_id`	string	«А40-123456/2023» или ID НПА
`sources[].title`	string	Заголовок документа
`sources[].relevance`	float	Оценка релевантности 0–1
`sources[].fragment`	string	Цитата из документа

7. AI-пайплайн

> Сейчас подключена заглушка (`services/ai_stub.py`). Реальный пайплайн подключается на следующем этапе без изменения интерфейса функции — только замена внутренней реализации.

1. QUERY PARSER	2. EMBEDDING	3. VECTOR SEARCH	4. RERANKER	5. RAG + LLM
`LLaMA 3.1 8B`	`Sentence-BERT`	`Qdrant`	`Cross-encoder`	`Qwen2.5 7B`
Разбирает запрос, выделяет тип спора, стороны, факты	Запрос → вектор 768 измерений	Cosine similarity, топ-20 кандидатов	Точная оценка пар запрос–документ, топ-5	Ответ строго по топ-5 документам, с источниками

QDRANT КОЛЛЕКЦИИ

КОЛЛЕКЦИЯ	СОДЕРЖИМОЕ	ИЗОЛЯЦИЯ
`public_docs`	НПА + судебная практика (общая база)	Все пользователи
`company_docs`	Внутренние документы компаний	Фильтр по `company_id`

8. Требования к качеству AI

МЕТРИКА	ЦЕЛЬ MVP	КАК ПРОВЕРЯЕМ
Время ответа	< 10 секунд	Ручной замер на 20 запросах
Релевантность топ-5	> 80% по теме	Ручная оценка юристом
Галлюцинации	0 фактов вне источников	Проверка каждого тезиса по ссылке
Одновременных пользователей	5–10	Нагрузочное тестирование
Полнота источников	Все тезисы со ссылкой	Контроль промпта

9. Сценарии работы пользователя

Основные пользовательские потоки для юриста-аналитика — целевой роли MVP.

1 Регистрация и первый вход — Триггер: новый клиент

01	Открывает страницу регистрации, вводит email, пароль и название компании	юрист
02	Создаёт аккаунт пользователя и компанию, выдаёт JWT-токен	система
03	Попадает на главный экран — строка поиска и пустая история	юрист

2 Поисковый запрос на естественном языке — Триггер: нужно найти норму / практику

01	Вводит вопрос: **«Какой срок исковой давности по трудовым спорам?»**	юрист
02	Опционально выставляет фильтры: регион, период, категория спора	юрист
03	Отправляет запрос, видит индикатор загрузки (~5–10 сек)	юрист
04	Возвращает краткий ответ AI + список из 3–5 источников с цитатами и оценкой релевантности	система
05	Читает ответ, проверяет источники, кликает на цитату чтобы раскрыть полный фрагмент	юрист
06	Сохраняет нужный документ в подборку или копирует ссылку	юрист

3 Работа с историей запросов

Триггер: возврат к прошлому поиску

01	Открывает раздел «История»	юрист
02	Видит список последних 50 запросов с датой и кратким текстом вопроса	система
03	Открывает нужный запрос — видит полный ответ и все источники как при первом поиске	юрист

4 Создание подборки документов

Триггер: работа над делом / проектом

01	Создаёт подборку с названием, например **«Дело Иванов vs ООО Ромашка»**	юрист
02	По ходу поисков добавляет релевантные документы в подборку кнопкой «Сохранить»	юрист
03	В разделе «Подборки» видит все сохранённые документы сгруппированно	юрист

5 Загрузка и поиск по внутреннему документу

Триггер: нужно найти что-то во внутреннем регламенте / договоре опционально

01	Открывает раздел загрузки, перетаскивает файл **PDF или DOCX**	юрист
02	Принимает файл, нарезает на чанки, строит векторное представление и сохраняет в отдельную Qdrant-коллекцию компании. Показывает статус: «Индексируется...»	система
03	Получает уведомление «Документ готов к поиску»	юрист

04	Вводит запрос и включает переключатель **«Искать во внутренних документах»**	юрист
05	Выполняет поиск по коллекции компании, изолированной от других клиентов. Ответ содержит цитаты из загруженного документа	система
06	Видит ответ с привязкой к страницам и фрагментам исходного файла	юрист

10. UX-требования

ПРИНЦИПЫ ИНТЕРФЕЙСА

Поиск — главное	Строка поиска — единственный элемент в центре экрана при открытии. Никаких баннеров, туториалов и отвлекающих блоков.
Каждый тезис — со ссылкой	AI-ответ никогда не показывается без источников. Источники визуально привязаны к конкретным утверждениям в тексте.
Прозрачность процесса	Пока AI думает — показываем прогресс («Ищу документы… Анализирую…»), а не просто спиннер. Юрист понимает, что происходит.
Читаемость — не красота	Минимум декора, максимум типографики. Юридический текст должен легко читаться, не перегружая глаз. Светлая тема по умолчанию.
Одно действие — один клик	Сохранить в подборку, скопировать цитату, раскрыть фрагмент — каждое действие доступно без перехода на другую страницу.

ЭКРАНЫ MVP

Главный экран

Центральная строка поиска, панель фильтров, последние 3 запроса из истории

`SearchBar` `Filters` `RecentQueries`

Страница результата

AI-ответ с нумерованными ссылками, список источников с цитатами и оценкой релевантности

`AnswerBlock` `SourceList` `SaveButton`

История

Список запросов с датой, кратким текстом; клик раскрывает полный ответ

Подборки

Список подборок пользователя; внутри — сохранённые документы с заголовками

`QueryList` `QueryDetail`

`CollectionList` `DocumentList`

Авторизация

Единая форма входа / регистрации с переключением. Минимум полей.

`LoginForm` `RegisterForm`

СОСТОЯНИЯ ИНТЕРФЕЙСА

ЭКРАН	ПУСТОЕ СОСТОЯНИЕ	ЗАГРУЗКА	ОШИБКА
Главный экран	Подсказки: 3 примера запросов	—	—
Результат поиска	«Ничего не найдено — попробуйте переформулировать»	Прогресс-бар с текстом этапа	«Сервис временно недоступен, попробуйте позже»
История	«Вы ещё не делали запросов»	Скелетон-список	—
Подборки	«Создайте первую подборку»	—	—